

# 時系列分析

## ハンズオン#2

# 進行予定

## 第2回 「ARIMAモデルを書いてみる」

- ARモデル
- MAモデル
- ARMAモデル
- ARIMAモデル
- 優れたモデルとは何か
- それぞれのモデルを書いてみる[ハンズオン]
- モデルの評価を行う[ハンズオン]


# 講師自己紹介

- 氏名：大久保 亮介
- 現在，薬学部4年 漢方薬専攻（予定）
- 担当講義：基礎統計→CNN，高校数学

# 第1回の復習

# 時系列分析とは？

過去のデータから、  
将来のデータ変化を  
予測する




# 構成要素


- 自己相関
- 周期的変動
- トレンド
- 外因性
- ホワイトノイズ

# 構成要素ごとに分解


もとのグラフ




トレンド



季節性



ホワイトノイズ



# ホワイトノイズ

将来を予測する情報がない雑音

t地点のホワイトノイズ:  $\epsilon_t$

- ・ 期待値は0
- ・ 分散は一定
- ・ 自己相関が0

$$E(\epsilon_t) = 0$$

$$\text{Cov}(\epsilon_t, \epsilon_{t-k}) = \begin{cases} \sigma^2, & k = 0 \\ 0, & k \neq 0 \end{cases}$$



# ホワイトノイズの例

実用的には正規分布にしたがうものを用いる

$$\epsilon_t \sim N(0, \sigma^2)$$

iid系列：  
データが独立




# ランダムウォーク

iid系列の累積和

$$y_t = y_{t-1} + \epsilon_t$$

$$\epsilon_t = -1 \text{ or } 1$$

$$\epsilon_t \sim N(0, \sigma^2)$$



# 定常過程の定義

期待値は時点によらず一定  $E(y_t) = \mu$

自己共分散は  
時点によらず  
時間差のみに依存

$$\begin{aligned} \text{Cov}(y_t, y_{t-k}) &= E[(y_t - \mu)(y_{t-k} - \mu)] \\ &= \gamma_k \end{aligned}$$

ARモデル

# ARモデル

自己回帰モデル (AutoRegressive model)


1次 AR(1) :  $y_t = c + \phi_1 y_{t-1} + \epsilon_t \quad \epsilon_t \sim N(0, \sigma^2)$

例題 :  $y_t = 1 + 0.5y_{t-1} + \epsilon_t$

$y_0 = 0, \epsilon_t = 0$  のときの  
 $y_1, y_2, y_3$  を計算せよ

p次 AR(p) :  $y_t = c + \sum_{i=1}^p \phi_i y_{t-i} + \epsilon_t \quad \epsilon_t \sim N(0, \sigma^2)$

# AR(1)のグラフ



# AR(1)のパラメータ

期待値

$$\mu = \frac{c}{1 - \phi_1}$$

分散


$$\gamma_0 = \frac{\sigma^2}{1 - \phi_1^2}$$

自己相関

$$\rho_k = \phi_1 \rho_{k-1}$$

Yule-Walker方程式

# AR(1)のコレログラム





MAモデル

# MAモデル

移動平均モデル (Moving Average model)


1次 MA(1) :  $y_t = \mu + \epsilon_t + \theta_1 \epsilon_{t-1}$

例題 :  $y_t = 1 + \epsilon_t + 0.5\epsilon_{t-1}$

$\epsilon_0 = 0.1, \epsilon_1 = 0.3, \epsilon_2 = 0.5$  のときの  
 $y_1, y_2$  を計算せよ

q次 MA(q) :  $y_t = \mu + \sum_{j=1}^q \theta_j \epsilon_{t-j} + \epsilon_t$

# MA(1)のグラフ



# MA(1)のパラメータ

期待値

$$E(y_t) = \mu$$

常に定常

分散


$$\gamma_0 = (1 + \theta_1^2)\sigma^2$$

自己相関

$$\rho_1 = \frac{\theta_1}{1 + \theta_1^2}$$

注意：理論上，2次以降の自己相関は0

# MA(1)のコレログラム




ARMAモデル

# ARMAモデル

自己回帰移動平均モデル (**AR** + **MA**)

$$\text{AR}(p,q) : y_t = c + \sum_{i=1}^p \phi_i y_{t-i} + \sum_{j=1}^q \theta_j \epsilon_{t-j} + \epsilon_t$$
$$\epsilon_t \sim N(0, \sigma^2)$$



# 補足：ARの定常条件

## AR特性方程式

$$1 - \phi_1 z - \dots - \phi_p z^p = 0$$

のすべての解の絶対値が1より大きい

例：AR(1)

$$1 - \phi_1 z = 0 \quad \text{より} \quad z = \phi_1^{-1}$$

$|\phi_1| < 1$  のとき定常



# 補足：MAの反転可能性

AR( $\infty$ )に書き直せるMA過程は反転可能

MA特性方程式

$$1 + \theta_1 z + \dots + \theta_p z^p = 0$$

のすべての解の絶対値が1より大きい

例：MA(1)

$1 + \theta_1 z = 0$  より  $|\theta_1| > 1$  のとき反転可能


# 補足：ARとMAとの関係

## 反転可能なMA(1)

$$y_t = \mu + \epsilon_t + \theta_1 \epsilon_{t-1} \quad (\mu = 0)$$

AR( $\infty$ )

$$\epsilon_t = -\theta_1 \epsilon_{t-1} + y_t$$



$$y_t = \sum_{k=0}^{\infty} (-\theta)^k y_{t-k} + \epsilon_t$$

$$= (-\theta)^m \epsilon_{t-m} + \sum_{k=0}^{m-1} (-\theta)^k y_{t-k}$$


$$\rightarrow \sum_{k=0}^{\infty} (-\theta)^k y_{t-k} \quad (m \rightarrow \infty)$$

ARIMAモデル

# ARIMAモデル

自己回帰和分移動平均モデル (AR + Integrate +MA)

d階差分をとった系列が  
ARMA(p,q)にしたがう過程  
→ARIMA(p,d,q)




# 補足：ARIMAの派生

- SARIMA (**S**easonal~) :  
季節成分を加えたモデル
- ARIMAX (~with e**X**ogenous variables) :  
外因性を加えたモデル

優れたモデルとは何か

# tast\_dataによる予測

Data



Train Test

いいモデルの推測

精度の算出

# モデル選択

例：ARMA(p,q)の次数決定

手当たり次第に次数を当てはめて、  
AICなどで評価する

$$AIC = -2L(\hat{\theta}) + 2k$$

最大化 パラメータの  
対数尤度 数

→小さいほど、予測能が良い



# モデル評価→同定

- ・ 定常性：AR項

特性方程式について、  
すべての解の絶対値が1より大きい

- ・ 反転可能性：MA項

- ・ 残差の自己相関 **Ljung-Box検定**

- ・ 残差の正規性 **Jarque-Bera検定**

# ナイーブ予測

その精度が高いと言えるか？

→単純なモデルと比較

- 過去の平均値を予測値として出す（ホワイトノイズ）
- 前地点の値を予測値として出す（ランダムウォークなど）

→予測モデル>ナイーブ予測で  
予測モデルの意味がある

それぞれのモデルを書いてみる[ハンズオン]

モデルの評価を行う[ハンズオン]